

$$Ax=b$$

$$\Rightarrow A_{1,:} x = b_1$$

$$A_{2,:} x = b_2$$

⋮

$$A_{m,:} x = b_m$$

• 逆矩阵: A^{-1} def: $A^{-1}A = I$ (对于方阵, 右逆 = 左逆)

• 对于 $Ax=b$:

• A^{-1} 存在: 对于每个 b 恰好存在一解

• 可能无解/多解.

• x, y 为 $Ax=b$ 解 $\Rightarrow \alpha x + (1-\alpha)y$ 也是 $Ax=b$ 的解.

• $Ax=b$ 可以看成将 A 中列向量组合成 b . (线性组合)



• linear combination: $\sum_i c_i v^{(i)}$

• span (生成子空间): set of every linear combination for some set of vectors.

• $Ax=b$ 有解 $\Leftrightarrow \vec{b}$ 在 A 列向量的 span 中 (即 $\vec{b} \in \text{col}(A)$ or A 的值域)

• $Ax=b$ 对任意 b 有解: $\text{col}(A) = \mathbb{R}^m$

必要条件: $n \geq m$ 充分条件: 恰有 m 个 linearly independent 的向量 $\in \text{col}(A)$

• $Ax=b$ 唯一解: A 可逆方阵.

• 范数: (norm)

$$\|x\|_p = \left(\sum_i |x_i|^p \right)^{1/p}, \quad p \in \mathbb{R}, p \geq 1$$

• 作用: vector 映射到 scalar.

• 性质: ① $f(0) = 0$

$$② f(x+y) \leq f(x) + f(y)$$

③ $\forall \alpha \in \mathbb{R}, \quad f(\alpha X) = |\alpha| f(X).$

• $p=2$ 时: 为 Euclidean norm.

• $L^2 \Leftrightarrow \|X\|$

• $p=1$ 时: $L^1 = \sum_i |X_i|$

当 0 与非 0 元素之间差异重要时使用.

• L^0 范数: 表示非零元素数量.

• L^∞ 范数: max norm (最大范数)

$$\|x\|_\infty = \max_i |X_i|$$


(表示绝对值最大的元素)

• Frobenius 范数: $\|A\|_F = \sqrt{\sum_{i,j} A_{i,j}^2}$

• 用于矩阵

• 点积可以用范数表示:

$$x \cdot y = \|x\|_2 \|y\|_2 \cos \theta$$



• 特殊矩阵, 向量:

• 对角矩阵:

$$D_{i,j} = \begin{cases} d_{ii}, & i=j \\ 0, & i \neq j \end{cases}$$

• $\text{diag}(v)$: 表示以向量 v 构造的对角矩阵.

· 好处: 乘法计算高效

$$\hookrightarrow \text{因为 } \text{diag}(v)x = vx, \text{ 复杂度 } O(n)$$

$$\text{且 } \text{diag}(v)^{-1} = \text{diag}([1/v_1, \dots, 1/v_n]^T)$$

\Updownarrow

$$\begin{pmatrix} \frac{1}{v_1} & & \\ & \frac{1}{v_2} & \\ & & \ddots \\ & & & \frac{1}{v_n} \end{pmatrix}$$

· 并非所有矩阵都是方阵

$$\text{ex: } \begin{pmatrix} 1 & & \\ & 1 & \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} \text{ or } \begin{pmatrix} 1 & & 0 & 0 \\ & 1 & 0 & 0 \\ & & 1 & 0 & 0 \\ & & & 1 & 0 & 0 \end{pmatrix}$$

也能高效计算

· 对称矩阵:

$$\cdot \text{def: } A = A^T$$

· 同于不依赖顺序的双参数函数:

如 A_{ij} 表示 i 到 j 的距离, $A_{ij} = A_{ji}$.

· 一定能找到一组正交单位 eigenvector

· 性质: ① 特征值均为实数

② 特征向量正交. (同一特征值能选正交)

· 定理: 正负有几个正数, 特征值就有几个正数

· 单位向量 (unit vector):

$$\cdot \|x\|_2 = 1$$

· 正交矩阵:

orthonormal: ① 向量之间相互正交
② $\text{norm} = 1$

· def: 行向量, 列向量分别构成正交的矩阵

☆

$A \text{diag}(\lambda)$: A 列向量线性组合 —— $([1] [1] [1]) \begin{pmatrix} \lambda_1 & \lambda_2 & \lambda_3 \end{pmatrix}$

$\text{diag}(\lambda) \cdot A$: 归一化处理

· 奇异值分解: (SVD: singular value decomposition)

· 将矩阵分解为奇异向量与奇异值 (singular vector, singular value)

· 每个实数矩阵都有一个奇异值分解, (但不一定有特征分解)

$$A = U D V^T \quad (U, V \text{ 为正交矩阵}, D \text{ 为对角矩阵})$$

$\begin{matrix} \swarrow & | & \searrow & \searrow \\ m \times n & m \times m & m \times n & n \times n \end{matrix}$

U 的列向量: 左奇异向量, 是 AA^T 的特征向量

V 的列向量: 右奇异向量. $A^T A$ 的特征向量

· A 的奇异值 def square roots of eigenvalues of $A^T A$

· SVD 最有用的性质是拓展矩阵求逆到非方阵上.

$$A^T A = V \Sigma^T U^T U \Sigma V^T = V \Sigma^T \Sigma V^T$$

$$A A^T = U \Sigma V^T V \Sigma^T U^T = U \Sigma \Sigma^T U^T$$

· 补充:

$$C P^T = P^T$$

· orthogonally diagonalizable: exist orthogonal matrix P : diagonal matrix D
such that $A = P D P^T = P D P^{-1}$

· thm: Orthogonally diagonalizable \Leftrightarrow symmetric

• SVD 推导:

• 背景:

A : $m \times n$ matrix

$A^T A$ is symmetric and orthogonally diagonalized

$\{v_1, \dots, v_n\}$: an orthonormal basis for \mathbb{R}^n consisting of eigenvectors for

$\lambda_1, \dots, \lambda_n$: eigenvalues of \mathbb{R}^n

$A^T A$

$$\|Av_i\|^2 = (Av_i)^T (Av_i) = v_i^T A^T A v_i = v_i^T \lambda_i v_i = \lambda_i$$

\therefore eigenvalues of $A^T A$ are nonnegative.

let $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$

• singular value: $\sigma_i = \sqrt{\lambda_i}$, $\sigma_1 \dots \sigma_n$

• singular value σ_i is the length of Av_i

• Thm: suppose A has r nonzero singular values.

Then $\{Av_1, \dots, Av_r\}$ is an orthonormal basis for $\text{Col } A$
rank = r

• Thm: $D = \text{diag}(\sigma)$, $\sigma = [\sigma_1, \dots, \sigma_r]$, $\sigma_1 \geq \dots \geq \sigma_r > 0$.

there exists an $m \times m$ orthonormal matrix U
 $n \times n$ orthonormal matrix V

such that: $A = U \Sigma V^T$

· SVD 计算:

$$1. A^T A = V \Sigma^T \Sigma V^T \Rightarrow V$$

$$2. A A^T = U \Sigma \Sigma^T U^T \Rightarrow U$$

· Moore-Penrose 伪逆:

· 问题: 解 $Ax = y$, 希望得到左逆 B , 使得 $x = By$

· A 的伪逆定义:

$$A^+ = \lim_{\alpha \rightarrow 0} (A^T A + \alpha I)^{-1} A^T$$

· 计算:

$$A^+ = V D^+ U^T \quad (\text{奇异值分解得到 } U, D, U)$$

$$\hookrightarrow D^+ = \text{diag}([1/\sigma_1, \dots, 1/\sigma_n])^T$$

· $m < n$ 时, $x = A^+ y$ 为所有可行解中 $\|x\|_2$ 最小的

$m > n$ 时, 可能无解, 此时得到的解 x 使得 Ax 与 y 欧几里德距离 $\|Ax - y\|_2$ 最小

迹运算:

$$\cdot \text{def: } \text{Tr}(A) = \sum_i A_{i,i}$$

· 迹运算描述矩阵 Frobenius 范数:

$$\|A\|_F = \sqrt{\text{Tr}(A A^T)}$$

$$\cdot \text{Tr}(A) = \text{Tr}(A^T)$$

$$\cdot \text{Tr}(X_1 X_2 \cdots X_n) = \text{Tr}(X_n X_1 \cdots X_{n-1})$$

将最后一个矩阵移到最前面, 迹不变.

· 即使置换后矩阵形状变了，迹仍然不变

$$A \in \mathbb{R}^{m \times n}, B \in \mathbb{R}^{n \times m}, AB \in \mathbb{R}^{m \times m}, BA \in \mathbb{R}^{n \times n}$$

$$\text{但 } \text{Tr}(AB) = \text{Tr}(BA)$$

· a 为标量，则 $a = \text{Tr}(a)$

· 行列式：

· $\det(A)$ ，是将方阵 A 映射到实数的函数。

· 行列式等于特征值乘积

· 行列式的绝对值用来衡量矩阵参与矩阵乘法后空间扩大/缩小了多少

· $\det(A) = 0$ ，那么空间至少沿着某一维完全收缩，失去了所有体积

· $\det(A) = 1$ ，保持空间体积不变

如 半正定矩阵 (positive semidefinite matrix)

• def: 设 A 为对称矩阵, 若对任意向量 x , 都有 $x^T A x \geq 0$, 则称 A 为半正定矩阵.
($x \neq 0$)

• 性质: A 为半正定 $\Rightarrow \det A \geq 0$

II, A, B 为半正定 $\Rightarrow A+B$ 为半正定

III, $a \geq 0, A$ 半正定 $\Rightarrow a \cdot A$ 为半正定.

\hookrightarrow scalar

• 判定: 若 A 对称:

A 半正定 $\Leftrightarrow A$ 的特征值非负 $\Leftrightarrow \exists C \in \mathbb{R}^{n \times n}, A = C^T C \Leftrightarrow \text{Rank}[B] = r, B \in \mathbb{R}^{r \times n}, A = B^T B$

• 初等矩阵: (elementary matrix)

1. 行互换
2. 行倍数
3. j 行倍数 $+ i$ 行

I, 行互换: i 行, j 行所有元素互换.

$$T_{ij} = \begin{bmatrix} 1 & & & \\ & \ddots & & \\ & & 0 & 1 \\ & & 1 & 0 \\ & & & \ddots & \\ & & & & 1 \end{bmatrix}$$

$$T_{ij}^{-1} = T_{ij}$$

$$\det(T_{ij}) = -1$$

$$\therefore (T_{ij} A) = |A|$$

II, 行倍数: $T_i(m)$ i 行所有元素乘 m .

$$T_i(m) = \begin{bmatrix} 1 & & & \\ & \ddots & & \\ & & m & \\ & & & \ddots & \\ & & & & 1 \end{bmatrix}$$

$$T_i(m)^{-1} = T_i(1/m)$$

$$\det(T_i(m)) = m$$

$$\therefore |T_i(m) A| = m|A|$$

III, i 行 $+ m \cdot (j$ 行)

$$T_{ij}(m) = \begin{bmatrix} 1 & & & \\ & \ddots & & \\ & & 1 & \\ & & m & \\ & & & \ddots & \\ & & & & 1 \end{bmatrix}$$

$$T_{ij}(m)^{-1} = T_{ij}(-m)$$

$$\det(T_{ij}(m)) = 1$$

$$\therefore |T_{ij}(m) A| = |A|$$